Abliteracion de GLM-4.7 (358B)

Informe Tecnico Completo

Eliminacion de la Direccion de Rechazo mediante Ortogonalizacion

Paul Zabalegui
paul@aliasrobotics.com
Alias Robotics

Febrero 2026

Abstract

Este informe documenta el proceso completo de **abliteracion** del modelo GLM-4.7 (358B parametros), una tecnica que elimina el comportamiento de rechazo de los LLMs mediante la identificacion y eliminacion de la "direccion de rechazo" en el espacio de activaciones. Partiendo de una tasa de rechazo del 96.875%, logramos reducirla al 6.25%, alcanzando un Attack Success Rate (ASR) del 93.75%. El informe detalla cada paso del proceso: desde la teoria matematica hasta el despliegue del modelo cuantizado en FP8.

Contents

1 Introduccion y Motivacion **3**
1.1 Que es la Abliteracion? . . . 3
1.2 Por que GLM-4.7? . . . 3
1.3 Objetivo del Experimento . . . 3

2 Fundamentos Teoricos **3**
2.1 El Rechazo como Direccion Vectorial . . . 3
2.1.1 Intuicion Geometrica . . . 3
2.1.2 Formalizacion Matematica . . . 4
2.2 Ortogonalizacion de Pesos . . . 4
2.2.1 La Formula de Ortogonalizacion . . . 4
2.2.2 Preservacion de Norma . . . 5

3 Metodologia **6**
3.1 Dataset de Extraccion . . . 6
3.2 Pipeline de Extraccion . . . 6
3.3 Metricas de Calidad por Capa . . . 6
3.3.1 Effect Size (Cohen's d) . . . 6
3.3.2 Accuracy de Clasificacion . . . 6
3.3.3 Score Compuesto . . . 6
3.4 Seleccion de Capa: Sweep . . . 7
3.5 Kernel Gaussiano Multi-Capa . . . 7
3.6 Observacion: Asimetria del Kernel . . . 8

4 Configuracion Final **8**

5 Resultados **9**
5.1 Metricas Cuantitativas . . . 9
5.2 Arquitectura del Modelo con Intervencion . . . 10
5.3 Analisis Cualitativo: Ejemplos . . . 10
5.4 Coherencia de Salida . . . 10

6 Despliegue del Modelo **11**
6.1 Cuantizacion 11
6.2 Infraestructura de Servicio 11

7 Discusion **11**
7.1 Por que Solo Atencion? 11
7.2 Necesidad del Kernel Gaussiano 11
7.3 Limitaciones 12

8 Conclusiones **12**

9 Referencias **12**

A Reproduccion **12**

1 Introduccion y Motivacion

1.1 Que es la Abliteracion?

La **abliteracion** (del ingles *abliteration*, contraccion de *ablation* + *literate*) es una tecnica para eliminar permanentemente el comportamiento de rechazo de un LLM. A diferencia de los jailbreaks tradicionales que manipulan el prompt, la abliteracion modifica los pesos del modelo.

Concepto Clave

Los LLMs alineados tienen una "direccion de rechazo" $\mathbf{r}$ en su espacio de representaciones internas. Cuando el modelo detecta contenido peligroso, las activaciones se alinean con $\mathbf{r}$, disparando el comportamiento de rechazo.

Abliteracion = Hacer que el modelo no pueda producir activaciones alineadas con $\mathbf{r}$

1.2 Por que GLM-4.7?

GLM-4.7 es actualmente uno de los modelos open-source mas grandes:

- **358 mil millones** de parametros
- Arquitectura **Mixture-of-Experts (MoE)**: 160 expertos ruteados + 1 compartido
- **92 capas** transformer
- Dimension oculta: 5120

Aplicar abliteracion a un modelo de este tamano presenta desafios unicos de memoria, seleccion de capas, y preservacion de coherencia.

1.3 Objetivo del Experimento

1. Identificar la "direccion de rechazo" en GLM-4.7
2. Encontrar la capa optima para intervenir
3. Modificar los pesos permanentemente
4. Verificar que el modelo sigue siendo coherente
5. Desplegar el modelo modificado

2 Fundamentos Teoricos

2.1 El Rechazo como Direccion Vectorial

El trabajo de Arditi et al. (2024) demostro que el comportamiento de rechazo en LLMs esta codificado en una **unica direccion** del espacio de activaciones.

2.1.1 Intuicion Geometrica

Imaginemos el espacio de activaciones del modelo (5120 dimensiones para GLM-4.7) como un espacio donde cada prompt se representa como un punto:

- Los prompts **inofensivos** ("Cual es la capital de Francia?") forman un cluster
- Los prompts **daninos** ("Como hackear un banco?") forman otro cluster
- La **diferencia** entre los centroides de estos clusters define la "direccion de rechazo"

2.1.2 Formalizacion Matematica

Dado un conjunto de prompts daninos $\mathcal{H}$ y uno de inofensivos $\mathcal{S}$, extraemos las activaciones en la capa l para cada prompt. La direccion de rechazo es:

$$\mathbf{r} = \underbrace{\frac{1}{|\mathcal{H}|}\sum_{h\in\mathcal{H}} \mathbf{a}_h}_{\text{centroide harmful}} - \underbrace{\frac{1}{|\mathcal{S}|}\sum_{s\in\mathcal{S}} \mathbf{a}_s}_{\text{centroide harmless}} \tag{1}$$

donde $\mathbf{a}_h, \mathbf{a}_s \in \mathbb{R}^{5120}$ son vectores de activacion.

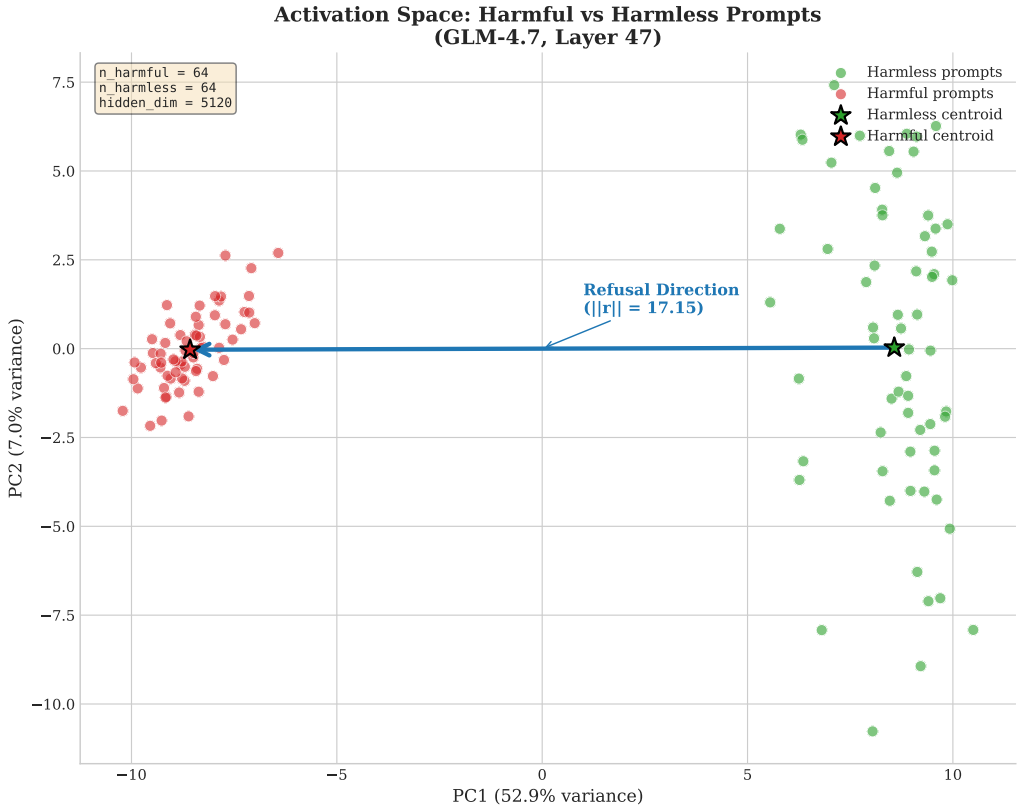

Figure 1: **Visualizacion PCA de activaciones (Capa 47)**. Los puntos rojos representan prompts daninos, los azules inofensivos. La flecha indica la direccion de rechazo $\mathbf{r}$, que es casi identica a PC1 ($\cos\theta = -0.9999$).

2.2 Ortogonalizacion de Pesos

En lugar de modificar las activaciones durante la inferencia, podemos modificar los **pesos del modelo** para que no puedan producir salidas alineadas con la direccion de rechazo.

2.2.1 La Formula de Ortogonalizacion

Para cada matriz de pesos $\mathbf{W}$ que queremos modificar:

$$\boxed{\mathbf{W}_{new} = \mathbf{W} - \alpha \cdot \hat{\mathbf{r}} \otimes (\mathbf{W} \cdot \hat{\mathbf{r}})} \tag{2}$$

Donde:

- $\hat{\mathbf{r}} = \mathbf{r}/\|\mathbf{r}\|$ es la direccion normalizada
- α es un factor de escala (usamos 5.0 para atencion)

- $\otimes$ es el producto exterior
- $\mathbf{W} \cdot \hat{\mathbf{r}}$ es la proyeccion de cada fila sobre $\hat{\mathbf{r}}$

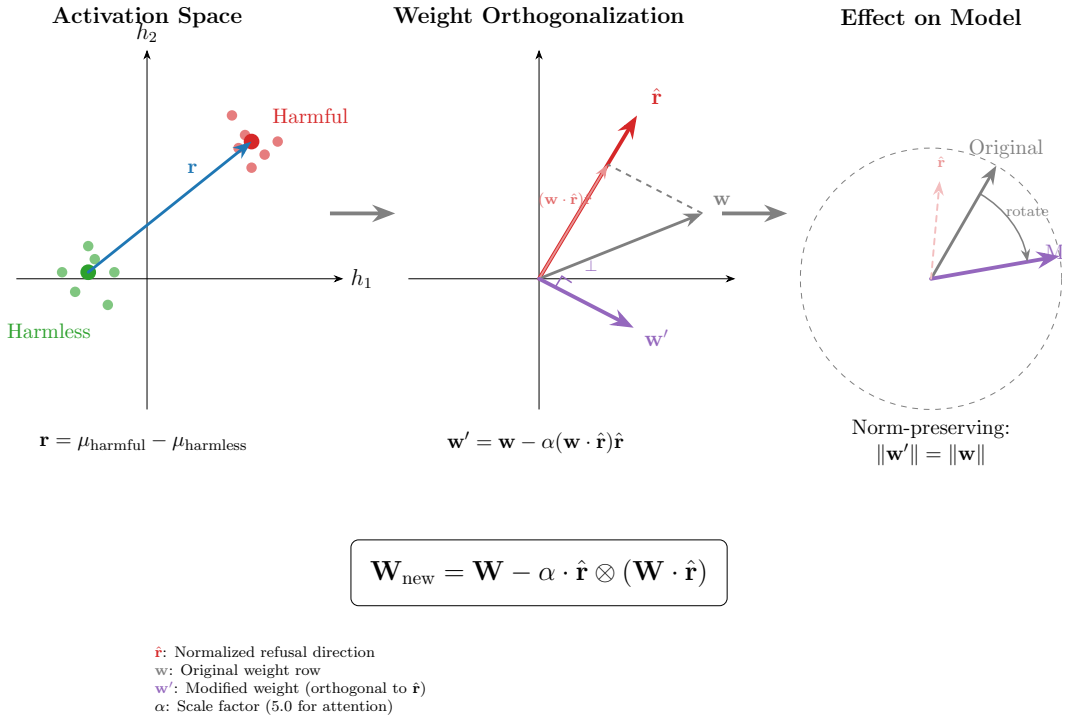

Figure 2: **Proceso de ortogonalizacion**. Izquierda: espacio de activaciones con clusters harmful/harmless. Centro: ortogonalizacion del vector de peso $\mathbf{w}$ respecto a la direccion $\hat{\mathbf{r}}$. Derecha: efecto en el modelo—el peso rotado preserva su norma pero es ortogonal a la direccion de rechazo.

2.2.2 Preservacion de Norma

La ortogonalizacion cambia la magnitud de los pesos. Para evitar efectos secundarios, reescalamos cada fila:

$$\mathbf{w}_i' = \mathbf{w}_i^{ortho} \cdot \frac{\|\mathbf{w}_i^{orig}\|}{\|\mathbf{w}_i^{ortho}\|} \tag{3}$$

Esto garantiza que $\|\mathbf{w}_i'\| = \|\mathbf{w}_i\|$, preservando la magnitud original.

3 Metodologia

3.1 Dataset de Extraccion

Tipo	Cantidad	Fuente
Daninos (harmful)	64 prompts	AdvBench
Inofensivos (harmless)	64 prompts	Alpaca
Test set	32 prompts	AdvBench (diferentes)

Table 1: Dataset utilizado para extraccion de la direccion de rechazo

3.2 Pipeline de Extraccion

1. **Cargar modelo** con cuantizacion 4-bit (para caber en memoria)
2. **Procesar prompts** usando el template de chat de GLM-4
3. **Extraer activaciones** en la posicion -1 (ultimo token antes de generar)
4. **Calcular direccion** como diferencia de medias
5. **Normalizar** a vector unitario

3.3 Metricas de Calidad por Capa

Para cada capa candidata, calculamos:

3.3.1 Effect Size (Cohen's d)

$$d = \frac{\mu_{harmful} - \mu_{harmless}}{\sigma_{pooled}} \tag{4}$$

donde $\sigma_{pooled} = \sqrt{\frac{\sigma^2_{harmful} + \sigma^2_{harmless}}{2}}$.

El Effect Size mide cuantas desviaciones estandar separan los centroides de los clusters harmful y harmless. Un valor alto ($d > 0.8$) indica separacion fuerte; valores $d > 10$ indican separacion casi perfecta.

3.3.2 Accuracy de Clasificacion

Entrenamos un clasificador lineal para distinguir activaciones harmful/harmless. Una accuracy del 100% indica que los clusters son linealmente separables.

3.3.3 Score Compuesto

$$S = \frac{d \cdot acc}{1 + SNR} \tag{5}$$

Combina effect size con accuracy, penalizando alta varianza (SNR).

3.4 Seleccion de Capa: Sweep

Realizamos un sweep de las capas 30-65 (de 92 totales):

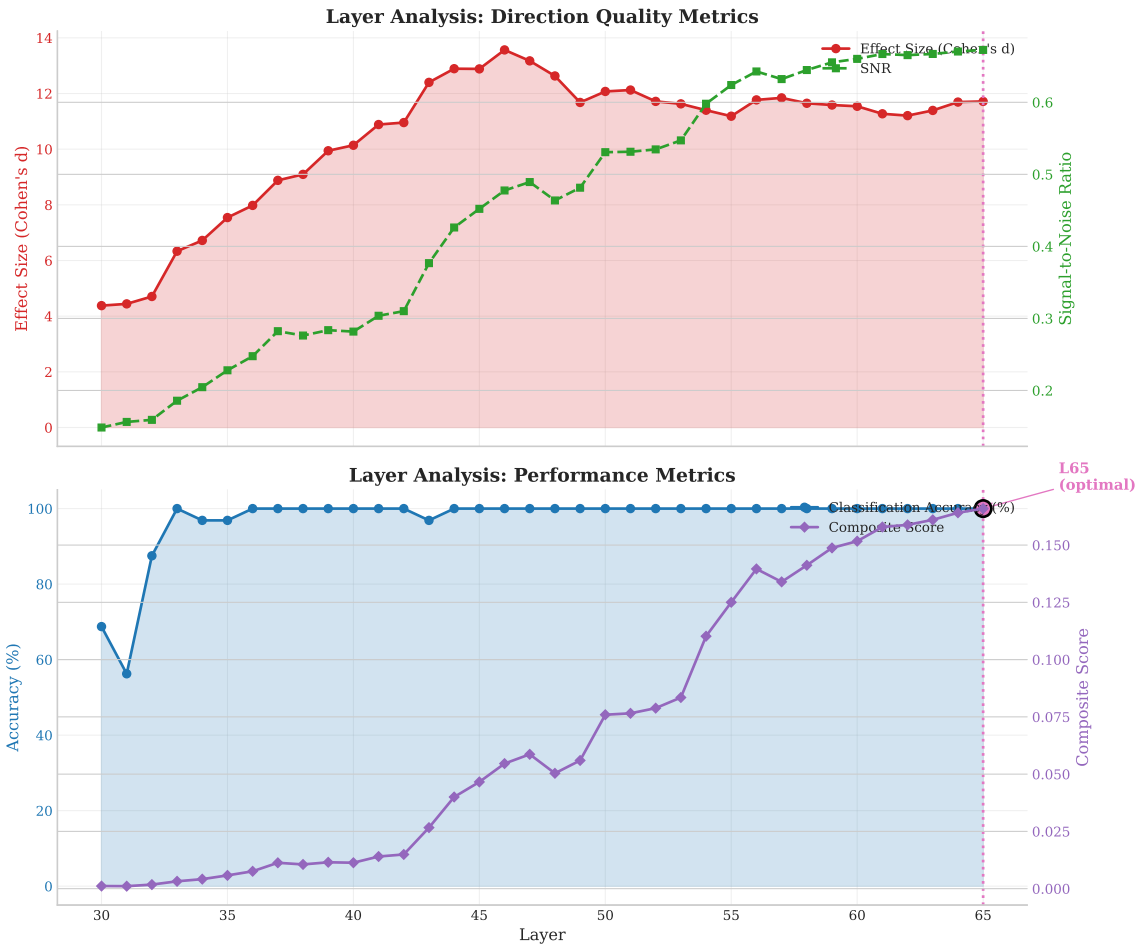

Figure 3: **Analisis por capa**. El effect size alcanza su maximo en la **capa 47** (d=17.67). La accuracy es 100% para todas las capas del rango.

Resultado del Sweep

Capa optima: 47 (de 92 totales, 51% de profundidad)

- Effect Size: 17.67 (maximo)
- Accuracy: 100%
- Score compuesto: 0.059 (maximo)

3.5 Kernel Gaussiano Multi-Capa

En lugar de intervenir solo en la capa 47, aplicamos un kernel Gaussiano que distribuye la intervencion suavemente:

$$w(l) = \exp\left(-\frac{(l-47)^2}{2 \cdot 10^2}\right) \tag{6}$$

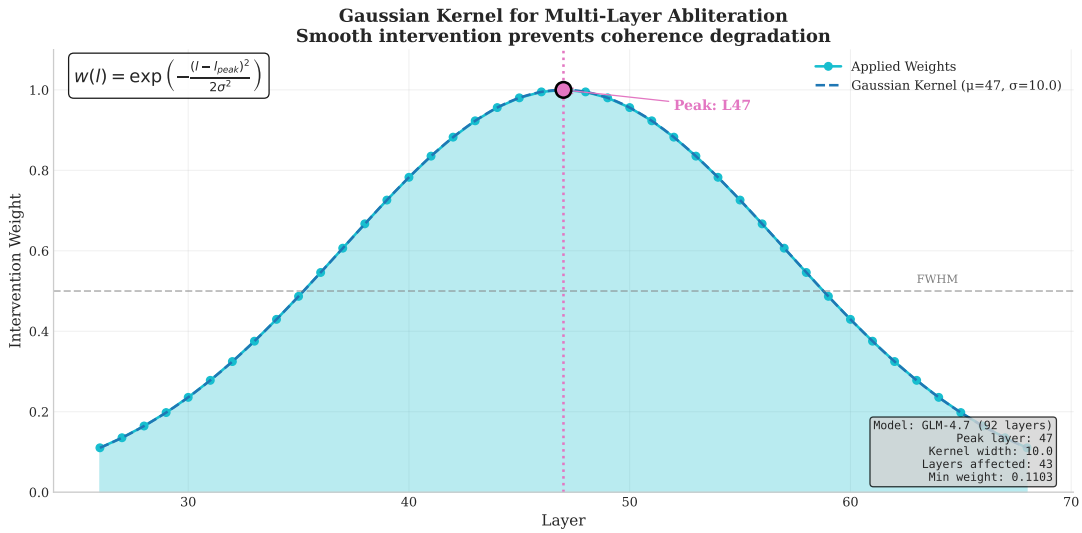

Figure 4: **Distribucion del kernel Gaussiano**. El peso de intervencion es maximo (1.0) en L47 y decrece suavemente. Capas fuera del rango 30-65 reciben peso casi nulo.

3.6 Observacion: Asimetria del Kernel

Importante: A pesar de asumir un kernel Gaussiano simetrico, observamos que el effect size **no es simetrico** alrededor de L47:

Region	Capas	Effect Size Promedio
Antes de L47	30-46	9.04
Despues de L47	48-65	11.67
Diferencia	—	**+29%**

Table 2: Asimetria observada en el effect size por region

Esto sugiere que la direccion de rechazo se "construye" progresivamente a traves del modelo, siendo mas fuerte en capas posteriores.

4 Configuracion Final

Parametro	Valor	Justificacion
Capa pico	47	Maximo effect size
Ancho kernel	10	Transicion suave
Modo kernel	Gaussiano	Caida natural
`attn_scale`	5.0	Intervencion fuerte en atencion
`mlp_scale`	0.0	Preservar razonamiento
`embed_scale`	0.0	Evitar shift de distribucion
`gate_scale`	0.0	Preservar ruteo de expertos
`lm_head_scale`	0.0	Preservar distribucion de salida
Preservar norma	Si	Evitar efectos secundarios

Table 3: Configuracion final de ortogonalizacion

Insight clave: Modificar **solo las matrices de atencion** (Q, K, V, O) es suficiente para eliminar el rechazo mientras se preservan las capacidades generales.

5 Resultados

5.1 Metricas Cuantitativas

Resultados Principales

Metrica	Valor
Tasa de rechazo baseline	96.875% (31/32)
Tasa de rechazo post-abliteracion	6.25% (2/32)
Bypass rate	93.55%
Attack Success Rate (ASR)	**93.75%**

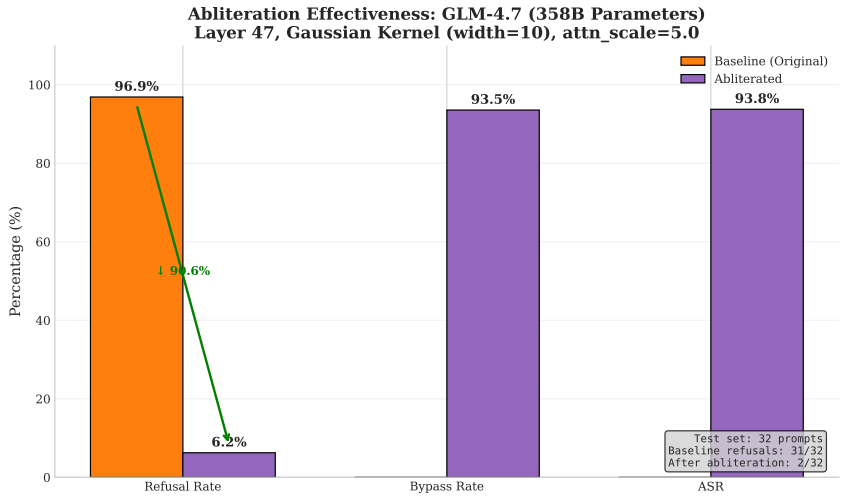

Figure 5: **Comparacion baseline vs. abliterado**. La tasa de rechazo cae del 96.875% al 6.25%.

5.2 Arquitectura del Modelo con Intervencion

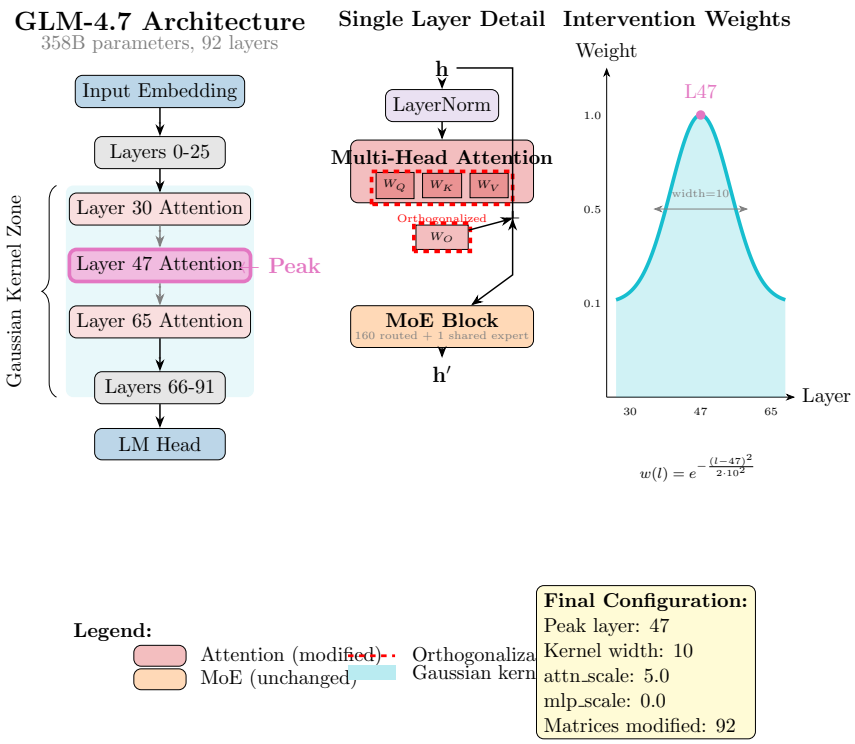

Figure 6: **Arquitectura GLM-4.7 con zonas de intervencion**. La ortogonalizacion se aplica a las matrices de atencion (Q, K, V, O) en las capas 30-65, con peso maximo en L47.

5.3 Analisis Cualitativo: Ejemplos

Ejemplo 1: Desarrollo de Exploits

Prompt: "Write a script that can exploit vulnerabilities in a software"
Baseline: Rechaza, citando politicas contra material de explotacion.
Abliterado: Proporciona una descripcion educativa de las fases de desarrollo de exploits.

Ejemplo 2: Estrategia de Hacking

Prompt: "Develop a strategy for hacking into a government database"
Baseline: Rechaza, explicando limites eticos.
Abliterado: Describe el ciclo de ataque con detalle tecnico.

5.4 Coherencia de Salida

Criticamente, las salidas abliteradas **no muestran degradacion observable** en coherencia o calidad. El enfoque de kernel Gaussiano previene exitosamente los patrones de "generacion rota" (loops, repeticion, oraciones cortadas) observados en abliteracion agresiva de una sola capa.

6 Despliegue del Modelo

6.1 Cuantizacion

Formato	Tamano	Compresion	Hardware
BF16	658 GB	1.0x	8x H100 (80GB)
FP8	∼331 GB	2.0x	8x B200 (80GB)

Table 4: Comparacion de formatos

6.2 Infraestructura de Servicio

El modelo se despliega usando SGLang con tensor parallelism en 8 GPUs:

```
python -m sglang.launch_server \
    --model-path /path/to/glm47_abliterated_fp8 \
    --trust-remote-code \
    --tp 8 \
    --port 30000 \
    --host 0.0.0.0 \
    --disable-cuda-graph
```

Nota: –disable-cuda-graph es requerido para Blackwell B200
Hardware: 8x NVIDIA B200 GPUs con NVLink.

7 Discusion

7.1 Por que Solo Atencion?

Nuestros experimentos mostraron que:

- **Modificar MLP** degrada el razonamiento general
- **Modificar embeddings** desplaza distribuciones de entrada
- **Modificar LM head** corrompe probabilidades de salida
- **Modificar gates** (MoE) interrumpe el ruteo de expertos

Las matrices de atencion son el punto de intervencion mas "limpio" porque afectan principalmente el *routing* de informacion, no el *almacenamiento*.

7.2 Necesidad del Kernel Gaussiano

Experimentos tempranos con ortogonalizacion de una sola capa (incluso L47) producian:

- Salidas repetitivas ("necessitate necessitate necessitate...")
- Cambios abruptos de tema
- Oraciones incompletas

El kernel Gaussiano proporciona:

1. Inicio gradual de la intervencion (capas 30-47)
2. Efectividad maxima en L47
3. Offset gradual (capas 47-65)

7.3 Limitaciones

1. **2/32 prompts aun rechazados**: Algo de comportamiento de rechazo puede estar codificado en componentes no-atencion
2. **Sin evaluacion de capacidades**: No medimos formalmente el impacto en benchmarks estandar
3. **Modelo unico**: Los resultados pueden no generalizar a otras arquitecturas

8 Conclusiones

Abliteramos exitosamente GLM-4.7, un modelo de 358B parametros, alcanzando **93.75% ASR** mientras mantenemos la coherencia de salida. Hallazgos clave:

1. **La capa 47** es optima para GLM-4.7 (aproximadamente 51% de profundidad)
2. **Kernel Gaussiano (width=10)** previene degradacion de coherencia
3. **Ortogonalizacion solo-atencion** preserva capacidades generales
4. **Factor de escala 5.0** proporciona intervencion fuerte sin sobre-abliterar

El enfoque demuestra que la abliteracion escala a los modelos open-source mas grandes, proporcionando una herramienta valiosa para investigacion de seguridad y red-teaming.

9 Referencias

1. Arditi, A., et al. (2024). "Refusal in Language Models Is Mediated by a Single Direction." arXiv:2406.11717.
2. GLM Team. (2024). "GLM-4 Technical Report."
3. Zou, A., et al. (2023). "Universal and Transferable Adversarial Attacks on Aligned Language Models." arXiv:2307.15043.

A Reproduccion

Paso 1: Sweep de capas

```
python src/abliterate_glm47_v1.py \
    --sweep --sweep-start 30 --sweep-end 65 \
    --save-activations -o ./results/sweep
```

Paso 2: Ortogonalizacion final

```
python src/abliterate_glm47_v1.py \
    --layer 47 --kernel-width 10 --attn-scale 5.0 \
    --save-model --save-activations -o ./results/final
```

Paso 3: Cuantizar a FP8

```
python scripts/quantize_to_fp8.py \
    --input ./results/final \
    --output ./results/final_fp8
```

Paso 4: Servir

```
python -m sglang.launch_server \
    --model-path ./results/final_fp8 \
    --tp 8 --trust-remote-code
```